

E-CUP

Ценность пользователей поиска

Команда Ежи

Илья Переверзев
Юлия Вязникова

Постановка задачи

~~*predict(деньги)*~~


*предсказываем суммарный GMV пользователя
в Поиске и Каталоге за следующие 30 дней*

>30 млн обезличенных записей об активности 250 000 клиентов
покупки, добавления в корзину, поисковые запросы и стоимость заказов
с 1 января 2025 по 13 февраля 2026

**нужно узнать суммарную стоимость заказов
для интервала с 14 февраля 2026 по 15 марта 2026**

недельный ритм, % от среднего дня

по всем 250 000 юзерам за весь период данных



~46% пользователей ничего не покупают на любом промежутке в 30 дней

суммы покупок различаются в тысячу раз (1% пользователей приносит 22% денег)

у всех пользователей есть активность в последний месяц

по выходным и будням пользователи ведут себя по-разному

Что это даёт

~46% пользователей ничего не покупают
на любом промежутке в 30 дней



используем ZILN

суммы покупок различаются в тысячу раз
(1% пользователей приносит 22% денег)



нужен $\log(\text{деньги})$

у всех пользователей есть активность в последний месяц



val строим под test

по выходным и будням пользователи ведут себя по-разному



агрегация по неделям

Делим данные на объекты выборки



Feature engineering

Объёмы в окнах

за 7 / 14 / 30 / 60 / 90 / 180 / 365 дней;
деньги, поиски, корзины, заказы, активные дни

Сколько дней прошло

с последней покупки, с последней корзины,
с последнего визита; стаж аккаунта

Тенденции: разгон или затухание

траты за 30 дней / траты за 180 дней;
тенденция трат по последним 8 неделям

Ритм покупок

типичный промежуток между покупками юзера;
просрочка = кол-во дней без покупки /
типичный промежуток

Воронка

корзина -> заказ за 14 дней
путь: через Поиск или Каталог

Чек

средний чек, медиана чека,
средние траты за день покупки

Что было год назад

траты в такое же 30-дневное
окно годом ранее


ИТОГО: 272 числа на юзера

и так на каждую из около 40 дат среза

Что нам может дать classic ml

выжали из агрегатов всё:

- LightGBM (+ режим dart)
- CatBoost
- XGBoost
- случайный лес
- две модели: купит ли? × на сколько?
- автотюнинг гиперпараметров
- отбор признаков, новые фичи



исчерпаны не алгоритмы, а агрегаты: они не видят порядок событий

порядок видит нейросеть GRU -> меняем представление данных

бустинг не выброшен: он остался в финальном ансамбле, потому что ошибается иначе, чем сети

Основная модель

вход: история как
последовательность

дни
поиски
корзины
заказы
вся платформа



52 шага: 38 недель + ближайшие 14 дней

GRU

p: купит ли?

вероятность покупки за 30 дней

μ: на сколько, если купит?

типичный чек юзера (в log-деньгах)

σ: разброс

насколько юзер непредсказуем

прогноз юзеру = $p \times \mu$

это матожидание log-денег: оптимум ровно под метрику RMSLE

Основная модель

зачем два числа:

- учимся оценивать вероятность покупки отдельно, т. к. почти половина юзеров ничего не купит
- модель учится предсказывать чек только на купивших, поэтому нули прогноз чека не портят

*плюс вспомогательные выходы
(деньги за 7 и 14 дней, число заказов)
в прогноз не идут,
но делают понимание модели глубже*

$$\text{штраф} = \text{промах}^2 / 2\sigma^2 + \log \sigma$$

промах = разница μ с реальным чеком

- стабильный юзер: ставит малую σ , любой промах дорог, модель выкладывается на нём
- хаотичный юзер: ставит большую σ , промах дешевле, но есть штраф за σ : модель меньше старается для него

Базовое решение

десятки обученных моделей-кандидатов

- GRU по неделям, разные сиды
- GRU + ближайшие 14 дней по дням
- GRU целиком по дням, 413 шагов
- GRU с короткой памятью (24 шага)
- GRU + табличные фичи (гибрид)
- LSTM
- LightGBM (режим dart)
- CatBoost
- пара моделей (купит ли? × на сколько?)
- ...и другие вариации

жадный отбор Каруаны


БАЗА

взвешенное среднее 13 моделей
(смешиваем в log-деньгах)

1.6462 на пабlike

9-е место на момент сабмита

Олимпиадный приёмчик



- база, вес 0, скор знаем
- проба, вес 1, скор скажет лидерборд
- вершина, идеальный вес, вычисляем не отправляя

как это работает

- берём поправку к базе из своей же модели
- отправляем с ней один сабмит, это проба
- два скор, две точки параболы. вычисляем идеальный вес и прибавку, не отправляя

Как это работает

y - истина

y' - наш предикт

F - поправка

вектора длины $N = 250\,000$, всё в $\log$ -пространстве

$$y' + k \cdot F$$

$$\begin{aligned} \text{score}(k)^2 &= (1/N) \sum_i (y'_i + k \cdot F_i - y_i)^2 = \\ &= \text{score}(0)^2 + 2k \cdot (1/N) \sum_i F_i (y'_i - y_i) + k^2 \cdot (1/N) \sum_i F_i^2 \end{aligned}$$

проба с $k = 1$ даёт $\text{score}(1)$, сумма найдена, а с ней и вершина

$$k^* = (\text{score}(0)^2 - \text{score}(1)^2 + (1/N) \sum_i F_i^2) / (2 \cdot (1/N) \sum_i F_i^2)$$

Как это работает

поправок 33, сабмитов 41, одна система уравнений

решение собираем из базы и всех поправок сразу

$$y' = \text{база} + k_1 F_1 + k_2 F_2 + \dots + k_{33} F_{33}$$

score² по-прежнему квадратичен по всем k , а неизвестных сумм с y теперь 33, по одной на каждую поправку

41 отправленный сабмит, состав каждого знаем, каждый даёт линейное уравнение на эти 33 суммы



решаем систему из 41 уравнения, все 33 суммы известны



вершина параболы в 33 измерениях, k^* всех поправок сразу и точный прогноз score до отправки

прогнозы сбывались с точностью 1e-6

Вишенка на торте

20 векторов поправки GRU, по одному на сид

- один сид
- среднее 20 сидов
- перпендикуляр к среднему, шум



Под конец обучили по 20 сидов основных моделей-поправок и усреднили все предсказания, чтобы уменьшить variance при неизменном bias

После чего поправки пересобрали, перемерили пробами, и жадный ансамбль Каруаны дал усреднённым предиктам веса больше, чем шумным

Ура всё сработало



Итоговая версия приватного рейтинга по результатам проверки решений (Этап 2).

#	Teams (316)		RMSLE ?	Last	Entries
1	Ежи	 			
2	ferrari strategy	  	1.6602338327	7d	73
3	tak nazivaemaya krutka		1.6615862555	7d	69
4	ICEQ		1.6616148454	7d	43
			1.6617150099	7d	100

Как формировались финальные сабмиты

оценка Джеймса-Стейна поджимает
коэффициент тем сильнее, чем ближе
он к шуму своего измерения

$$k' = k \cdot \max(0, 1 - \lambda \cdot \sigma^2 / k^2)$$

σ - шум одного измерения

λ - сила поджатия, у нас 0.3

финал 1, полное решение

33 поправки с идеальными коэффициентами
максимум на пабlike

паблик 1.6443877

финал 2, оценка Джеймса-Стейна

16 поправок, коэффициенты поджаты,
длина вектора весов 81% от полной

паблик 1.6447490